MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico individual · 20 %

Título del proyecto:	Análisis estadístico del riesgo de enfermedad coronaria a diez años
Estudiante:	Alexander Sepúlveda Ormazábal
Dataset:	Framingham Heart Study
Docente:	Jean Paul Maidana González
Fecha:	14/10/2026
Repositorio GitHub:	`https://github.com/alexander-seor/MCDI501-Proyecto-Framingham`

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información
Modalidad: Individual **Ponderación:** 20 % de la nota final
Entregables: Informe PDF (máx. 8 páginas, sin anexos) · Notebook `.ipynb` · Repositorio GitHub
Resultado de aprendizaje (RA1): aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.
Indicadores: ID1.2, ID1.3 e ID1.4.

Índice

1 Preparación y carga de datos **2**

2 Análisis exploratorio de datos **2**

2.1 Estadística descriptiva 2

2.2 Relaciones bivariadas 3

3 Estimación de parámetros **4**

4 Pruebas de hipótesis **5**

4.1 Presión sistólica según enfermedad coronaria 5

4.2 Hipertensión previa y enfermedad coronaria 5

5 Informe de avance del proyecto **6**

6 Notebook y repositorio GitHub **6**

Bibliografía **6**

1. Preparación y carga de datos

El proyecto estudia factores demográficos, conductuales y clínicos asociados con la ocurrencia de enfermedad coronaria durante diez años. El estudio de Framingham constituye una referencia para el análisis de factores cardiovasculares (National Heart, Lung, and Blood Institute, s. f.).

Para este trabajo se utiliza una versión del *Framingham Heart Study* publicada en Kaggle (Dileep, 2019), con 4.238 personas y 16 variables. La respuesta `TenYearCHD` toma el valor 1 cuando se registra el evento y 0 en caso contrario. La pregunta de análisis es: *¿qué diferencias se observan entre quienes desarrollaron y quienes no desarrollaron enfermedad coronaria durante el seguimiento?*

El archivo `framingham.csv` se cargó en Python sin modificarlo. Se verificaron dimensiones, tipos computacionales, valores únicos, duplicados y codificaciones. También se aplicaron intervalos amplios de plausibilidad para detectar errores evidentes de registro. Estos intervalos se utilizaron como control de calidad y no como límites diagnósticos. No se encontraron filas duplicadas ni registros fuera de las categorías o intervalos definidos.

La Tabla 1 resume la ausencia de datos. Cada procedimiento utiliza los casos disponibles para las variables involucradas e informa su tamaño muestral. No se imputaron valores en esta fase, porque ello habría requerido adoptar supuestos sobre el mecanismo de ausencia que todavía no han sido evaluados.

Tabla 1: Variables con datos faltantes.

Variable	Faltantes	%	Variable	Faltantes	%
`education`	105	2,48	`totChol`	50	1,18
`cigsPerDay`	29	0,68	`BMI`	19	0,45
`BPMeds`	53	1,25	`heartRate`	1	0,02
`glucose`	388	9,16			

Las variables binarias se trataron como cualitativas nominales; `education`, como ordinal; `age` y `cigsPerDay`, como cuantitativas discretas; y las mediciones clínicas restantes, como cuantitativas continuas. Esta distinción evita interpretar como promedios los códigos 0/1 y orienta la elección de tablas, gráficos y pruebas.

2. Análisis exploratorio de datos

2.1 Estadística descriptiva

La Tabla 2 combina medidas de tendencia central y dispersión. Cigarrillos diarios y glucosa presentan asimetría positiva; por ello, su media se interpreta junto con la mediana y el rango intercuartílico (RIC). La presión sistólica y el colesterol también exhiben observaciones elevadas.

Tabla 2: Resumen de variables numéricas.

Variable	n	Media	Mediana	DE	RIC
Edad (años)	4.238	49,58	49,00	8,57	14,00
Cigarrillos/día	4.209	9,00	0,00	11,92	20,00
Colesterol (mg/dL)	4.188	236,72	234,00	44,59	57,00
Presión sistólica (mmHg)	4.238	132,35	128,00	22,04	27,00
Presión diastólica (mmHg)	4.238	82,89	82,00	11,91	14,88
IMC	4.219	25,80	25,40	4,08	4,97
Frecuencia cardíaca (lpm)	4.237	75,88	75,00	12,03	15,00
Glucosa (mg/dL)	3.850	81,97	78,00	23,96	16,00

La Figura 1 permite comparar la forma de las distribuciones y muestra la diferencia entre media y mediana en las variables con mayor asimetría.

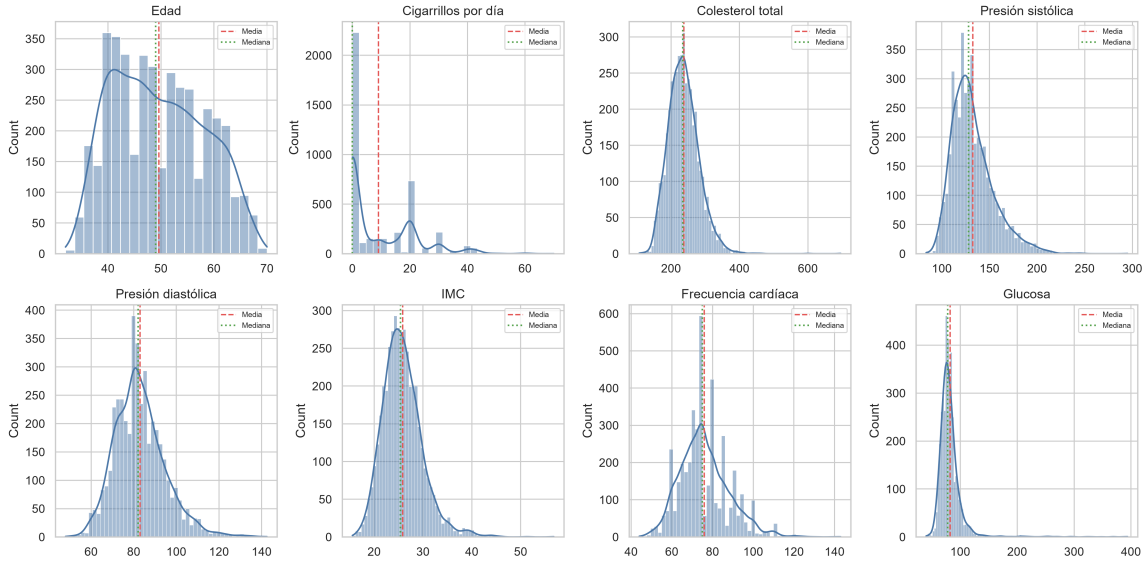


Figura 1: Distribuciones de las variables numéricas con media y mediana.

La respuesta está desbalanceada: 644 personas desarrollaron enfermedad coronaria (15,20 %) y 3.594 no la desarrollaron (84,80 %). El 31,05 % presenta antecedente de hipertensión, 49,41 % registra tabaquismo actual y 2,57 % tiene diabetes. La Figura 2 muestra simultáneamente el desbalance y la calidad de información.

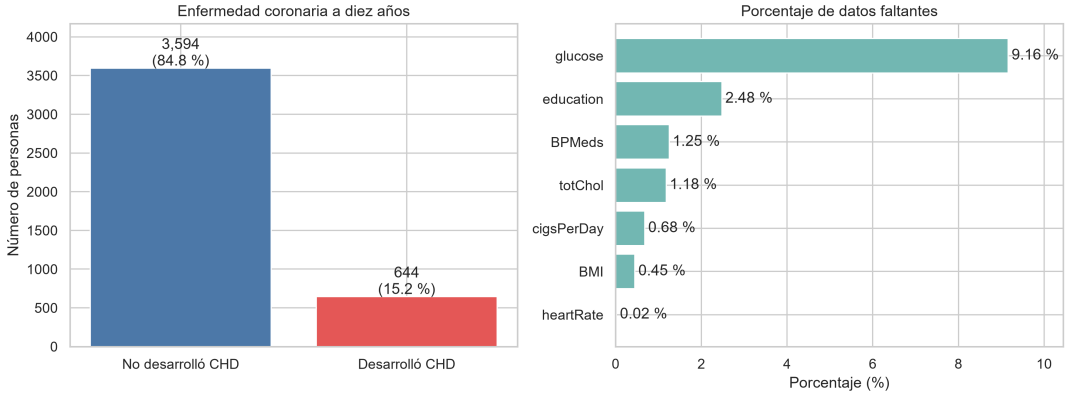


Figura 2: Distribución de la respuesta y porcentaje de datos faltantes.

2.2 Relaciones bivariadas

La matriz de Pearson de la Figura 3 identifica relaciones lineales. Presión sistólica y diastólica presentan la asociación más alta ($r = 0,78$). Respecto de `TenYearCHD`, las correlaciones mayores corresponden a edad ($r = 0,23$) y presión sistólica ($r = 0,22$). Debido a que la respuesta es binaria, estos valores equivalen a correlaciones punto-biseriales; no implican causalidad y pueden omitir relaciones no lineales. Cada coeficiente se calculó con los pares de datos disponibles, por lo que el tamaño muestral puede variar entre correlaciones.

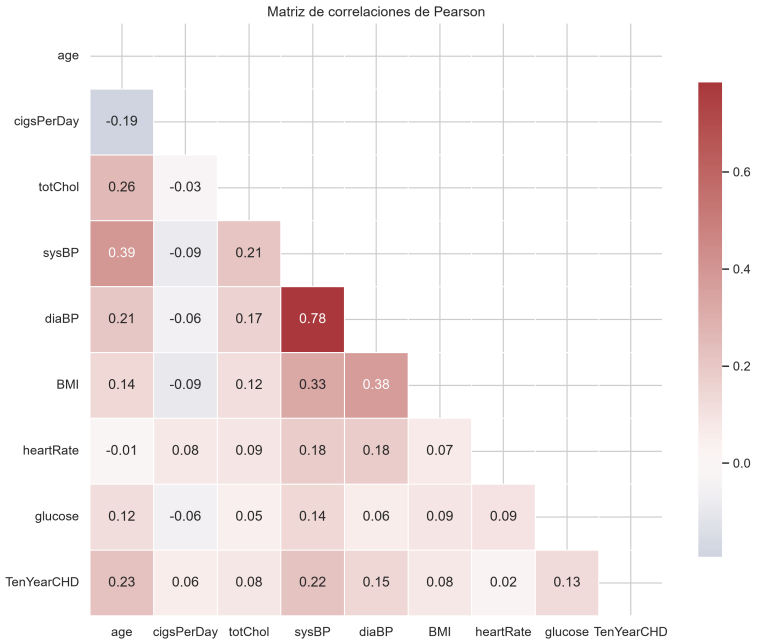


Figura 3: Matriz de correlaciones de Pearson (triángulo inferior).

Los diagramas de caja de la Figura 4 muestran mayor edad y presión sistólica en el grupo con enfermedad. Para colesterol existe un solapamiento considerable, mientras que glucosa presenta valores extremos.

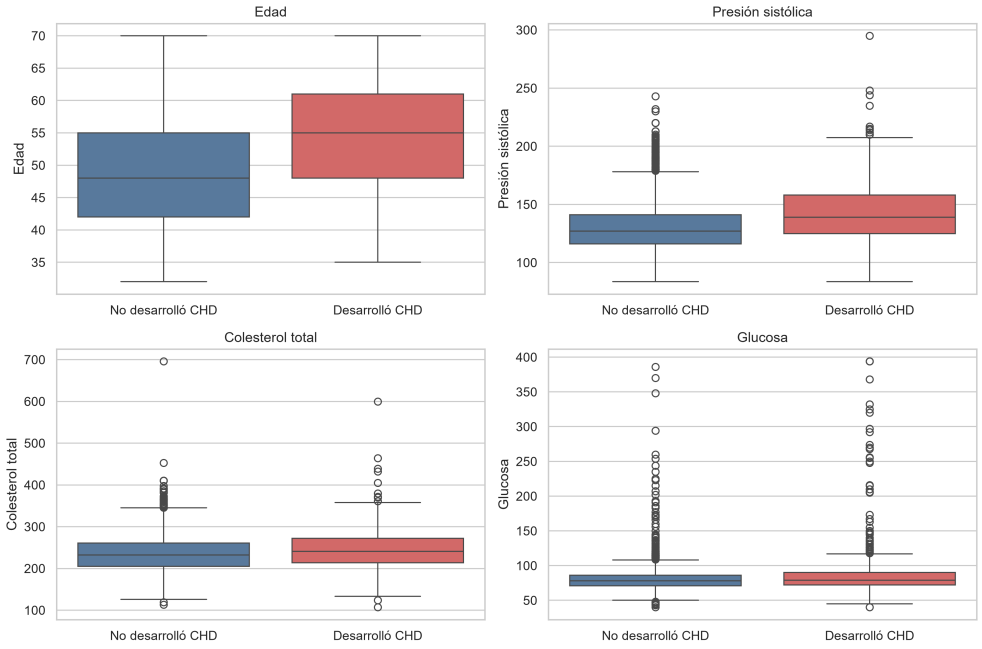


Figura 4: Comparación de variables clínicas y demográficas según enfermedad coronaria.

En el análisis categórico, 24,70 % de quienes presentan hipertensión desarrolló enfermedad, frente a 10,92 % del grupo sin dicho antecedente. La diferencia descriptiva según tabaquismo actual es menor (15,9 % frente a 14,5 %) y debe interpretarse junto con la intensidad, la duración del consumo y la edad.

3. Estimación de parámetros

Se estimaron las medias de edad, presión sistólica y colesterol total. Como la desviación estándar poblacional es desconocida, se utilizó un intervalo bilateral basado en t de Student:

$$\bar{x} \pm t_{0,975;n-1} \frac{s}{\sqrt{n}}.$$

Los tamaños muestrales son grandes, pero el uso de t mantiene explícita la incertidumbre asociada con la estimación de s. El procedimiento supone observaciones independientes y una muestra adecuada para representar la población de interés. La Tabla 3 presenta los resultados.

Tabla 3: Estimaciones puntuales e intervalos de confianza del 95 %.

Parámetro	n	**Estimación**	**IC 95 %**
Edad media	4.238	49,58 años	49,33–49,84
Presión sistólica media	4.238	132,35 mmHg	131,69–133,02
Colesterol total medio	4.188	236,72 mg/dL	235,37–238,07
Proporción de enfermedad coronaria	4.238	15,20 %	14,15 %–16,31 %

Para la proporción se empleó el intervalo de Wilson, implementado con *statsmodels* (Seabold & Perktold, 2010). Este método es más estable que la aproximación normal simple para respuestas binarias.

Con un 95 % de confianza, la edad media de la población representada por la muestra se encuentra entre 49,33 y 49,84 años. La presión sistólica media se sitúa entre 131,69 y 133,02 mmHg, mientras que el colesterol total medio se encuentra entre 235,37 y 238,07 mg/dL. Para la proporción de enfermedad coronaria, el intervalo compatible con los datos va de 14,15 % a 16,31 %.

Los intervalos no contienen al 95 % de las observaciones individuales ni expresan el riesgo de una persona específica. Su validez depende de la independencia de las observaciones, del procedimiento de muestreo y de la representatividad de la muestra.

4. Pruebas de hipótesis

Se fijó $\alpha = 0,05$ antes de realizar las pruebas. Este umbral limita al 5 % la probabilidad de rechazar H_0 cuando es verdadera, siempre que se cumplan los supuestos del procedimiento. La prueba de Welch se planteó de forma bilateral. La prueba de chi-cuadrado evalúa una asociación no direccional mediante la cola derecha de su distribución. Los cálculos se realizaron con SciPy (SciPy Community, 2026) y la significancia se complementó con intervalos y tamaños de efecto.

4.1 Presión sistólica según enfermedad coronaria

Se planteó $H_0 : \mu_{\text{CHD}} = \mu_{\text{sin CHD}}$ frente a $H_1 : \mu_{\text{CHD}} \neq \mu_{\text{sin CHD}}$. Cada fila corresponde a una persona y los grupos son mutuamente excluyentes, por lo que las observaciones se consideran independientes. Las distribuciones presentan asimetría moderada, pero los tamaños muestrales son suficientes para una comparación robusta de medias. Como las desviaciones difieren (26,69 frente a 20,46 mmHg), se aplicó t de Welch, que no exige igualdad de varianzas.

La media fue 143,62 mmHg con enfermedad ($n = 644$) y 130,33 mmHg sin enfermedad ($n = 3.594$). La diferencia fue 13,29 mmHg, IC 95 % $[11,11; 15,46]$, con $t = 12,015$, $gl = 783,9$ y $p < 0,001$. Se rechazó H_0. El tamaño $d = 0,617$ indica una diferencia estandarizada moderada. En términos prácticos, la presión sistólica es una variable relevante para el análisis multivariado posterior.

4.2 Hipertensión previa y enfermedad coronaria

Se contrastó H_0: ambas variables son independientes, frente a H_1: existe asociación. Cada persona aporta una sola observación y pertenece a una única categoría de cada variable. Todas las frecuencias esperadas superaron 199, por lo que se cumplen los supuestos de independencia de observaciones y suficiencia de frecuencias esperadas.

El resultado fue $\chi^2(1) = 132,611$, $p < 0,001$; se rechazó H_0. La magnitud fue baja a moderada (V de Cramér $= 0,177$). El riesgo observado fue 24,70 % con hipertensión y 10,92 % sin hipertensión, con riesgo relativo 2,26 y *odds ratio* 2,68. En términos prácticos, el antecedente de hipertensión identifica un grupo que requiere mayor atención en el análisis conjunto de factores cardiovasculares.

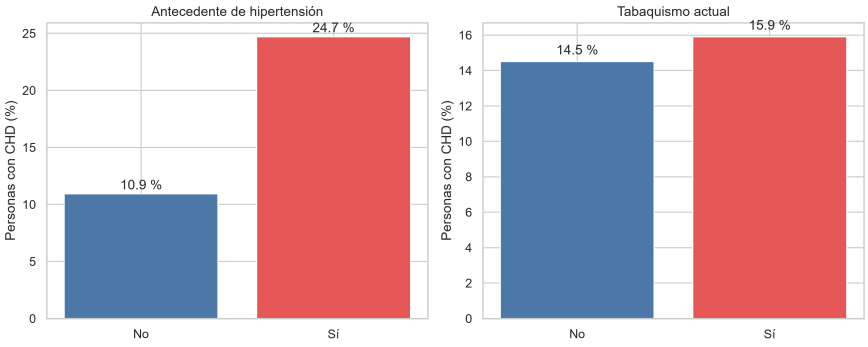


Figura 5: Porcentaje de enfermedad coronaria según hipertensión y tabaquismo actual.

Ambas pruebas describen asociaciones no ajustadas. No demuestran que presión sistólica o hipertensión causen por sí solas la enfermedad, pues edad, sexo, diabetes, tabaquismo y otros factores pueden confundir las comparaciones.

5. Informe de avance del proyecto

El avance consolida un flujo reproducible desde datos crudos hasta evidencia descriptiva e inferencial. Los resultados destacan edad, presión arterial y antecedente de hipertensión como variables relevantes para profundizar el estudio cardiovascular. La incertidumbre se comunicó mediante intervalos y las decisiones inferenciales se acompañaron con tamaños de efecto.

Las limitaciones principales son el diseño observacional, el desbalance de la respuesta y la ausencia de ajuste simultáneo por factores de confusión.

La mayor proporción de datos faltantes corresponde a glucosa, con 9,16 %. Antes de modelar será necesario estudiar el mecanismo de ausencia y definir un tratamiento reproducible que no altere injustificadamente la distribución de esta variable.

Como próximos pasos se propone estudiar relaciones multivariadas y comparar modelos predictivos con validación adecuada. Durante ese proceso se mantendrá la distinción entre descripción, asociación, predicción y causalidad.

6. Notebook y repositorio GitHub

El notebook `fase-2/sumativa-1/notebooks/sumativa_1_framingham.ipynb` ejecuta 18 celdas de código sin errores, fija la semilla 42, localiza la raíz del proyecto y valida dimensiones, codificaciones e intervalos de plausibilidad. También exporta cinco figuras a 300 dpi. Los datos originales permanecen en `fase-1/datos/raw/`; las dependencias están declaradas en `requirements.txt`. El historial y los entregables se encuentran en `https://github.com/alexander-seor/MCDI501-Proyecto-Framingham`.

Bibliografía

Dileep. (2019). *Logistic regression to predict heart disease* [Conjunto de datos]. Kaggle. `https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression`

National Heart, Lung, and Blood Institute. (s. f.). *Teaching datasets: Framingham Heart Study.* `https://biolincc.nhlbi.nih.gov/teaching/`

SciPy Community. (2026). *SciPy* (versión 1.18.1) [Software]. `https://scipy.org/`

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96). `https://doi.org/10.25080/Majora-92bf1922-011`