

MAGÍSTER EN CIENCIA DE DATOS

MCDI501 - Estadística Computacional

Evaluación Sumativa 2

Validación, simulación y remuestreo

Análisis del riesgo de enfermedad coronaria a diez años

Estudiante: Alexander Sepúlveda Ormazábal
Docente: Jean Paul Maidana González
Conjunto de datos: Framingham Heart Study
Fecha: 23 de octubre de 2026
Repositorio: MCDI501-Proyecto-Framingham

1. Propósito y estrategia de validación

En la Sumativa 1 se estimaron medias, correlaciones y diferencias entre personas con y sin enfermedad coronaria. En esta segunda etapa se revisa cuánto cambian esos resultados al remuestrear los mismos 4.238 registros y al reducir la influencia de valores extremos. Para ello se aplican bootstrap, una prueba de permutación, una simulación Monte Carlo y análisis de sensibilidad. Los datos originales no se modifican.

Componente	Procedimiento	Configuración
Medias	Intervalos clásico, bootstrap percentil y BCa	10.000 remuestras
Grupos CHD	Welch de S1 y permutación bilateral	10.000 permutaciones
Correlaciones	Bootstrap pareado de cinco correlaciones punto-biseriales	3.000 remuestras
Monte Carlo	Cohortes generadas desde prevalencia de hipertensión y tasas condicionales de CHD	10.000 cohortes de 1.000
Robustez	Recorte, winsorización, jackknife y bootstrap de diferencia recortada	Semilla 42

Cuadro 1: Diseño de validación reproducible.

El intervalo clásico aproxima la distribución muestral de la media; el percentil toma cuantiles de la distribución bootstrap; y BCa corrige sesgo y aceleración [2, 3]. La permutación usa la intercambiabilidad de las etiquetas bajo la hipótesis nula [4]. La simulación Monte Carlo aproxima la distribución de resultados hipotéticos bajo parámetros fijos [6]. El análisis se implementó con Python, NumPy, pandas, Matplotlib, seaborn y SciPy [7].

1.1. Criterio de interpretación

En este informe, un resultado se considera estable cuando cambia poco al repetir el análisis con remuestras de los mismos datos. Esto corresponde a una validación interna: no asegura que el resultado se mantenga en otra población, ni que la relación observada sea causal o tenga por sí sola utilidad predictiva.

Fuente de datos. El archivo analizado corresponde a la versión publicada por Dileep en Kaggle. La documentación del NHLBI se utilizó como referencia contextual sobre el Framingham Heart Study [1, 5].

2. Intervalos bootstrap para las medias

Variable	Media	Clásico		Percentil		BCa	
		Inf.	Sup.	Inf.	Sup.	Inf.	Sup.
Edad	49,5849	49,3268	49,8431	49,3259	49,8462	49,3268	49,8471
Presión sistólica	132,3524	131,6887	133,0161	131,6881	133,0109	131,7004	133,0231
Colesterol total	236,7216	235,3707	238,0724	235,3656	238,0499	235,4043	238,1034

Cuadro 2: Comparación de intervalos de confianza al 95 %.

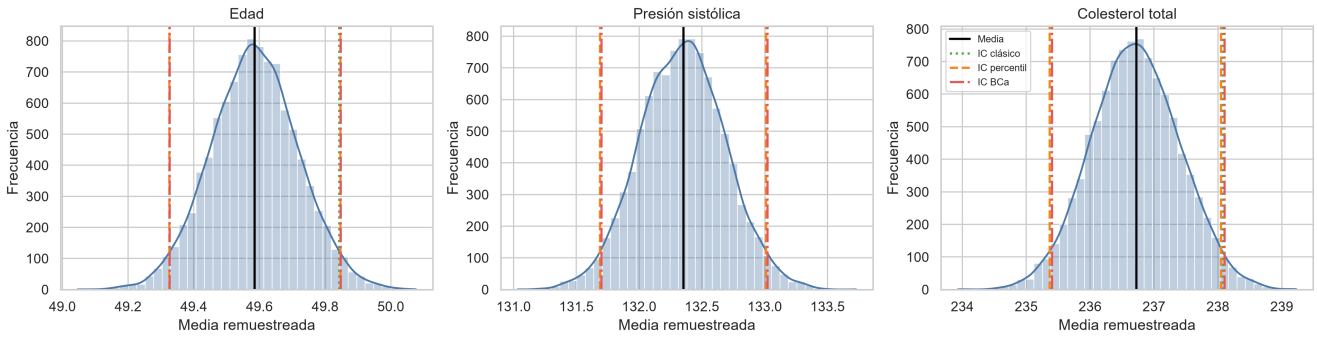


Figura 1. Distribuciones de las medias bootstrap y comparación de intervalos.

Los tres intervalos entregan prácticamente los mismos límites. Por eso, la estimación de estas medias cambia poco con el método elegido. De todas formas, esta coincidencia no resuelve los problemas de datos faltantes, valores extremos o representatividad de la muestra.

3. Prueba de permutación

La presión sistólica media fue 143,62 mmHg con CHD y 130,33 mmHg sin CHD, una diferencia de 13,29 mmHg. Ninguna de las 10.000 permutaciones produjo un valor tan extremo, por lo que se obtuvo $p = 0{,}00010$. El resultado apunta en la misma dirección que Welch en la Sumativa 1 ($p = 1{,}210 \times 10^{-30}$), aunque ambas pruebas no son idénticas cuando las dispersiones de los grupos difieren. En esta muestra, la presión media fue mayor entre quienes desarrollaron CHD. La comparación no está ajustada por edad, sexo u otros posibles factores de confusión.

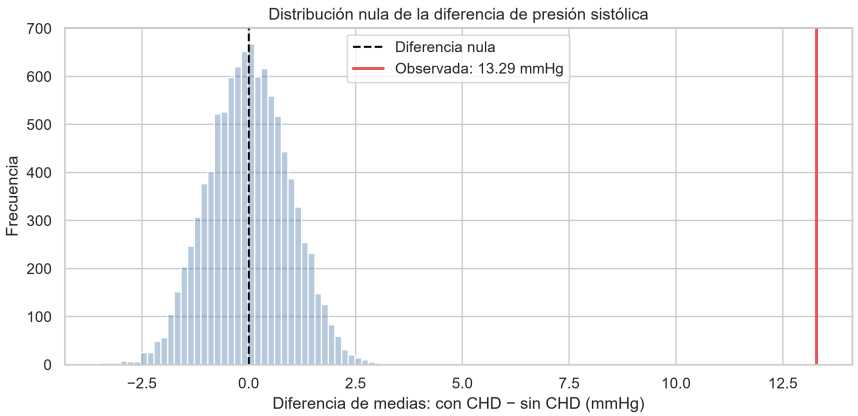


Figura 2. Distribución nula y diferencia observada de presión sistólica.

4. Estabilidad de las correlaciones

Variable	n efectivo	r observado	IC 95 % inferior	IC 95 % superior
Edad	4.238	0,2253	0,1964	0,2540
Presión sistólica	4.238	0,2164	0,1826	0,2494
Presión diastólica	4.238	0,1453	0,1115	0,1797
Glucosa	3.850	0,1255	0,0815	0,1680
Colesterol total	4.188	0,0822	0,0505	0,1135

Cuadro 3: Correlaciones con `TenYearCHD` e intervalos bootstrap.

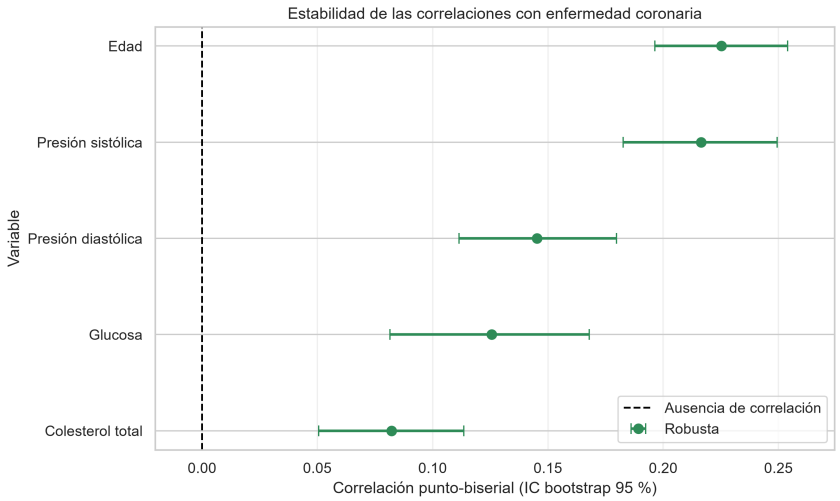


Figura 3. Estimaciones puntuales e intervalos bootstrap al 95 %.

En las 3.000 remuestras, los intervalos de las cinco correlaciones quedaron por encima de cero. Esto indica que el signo positivo se mantuvo dentro de esta muestra. Sin embargo, las asociaciones siguen siendo débiles o modestas y no bastan, por sí solas, para afirmar que las variables tengan buena capacidad predictiva. Glucosa, además, tiene menos casos completos y fue la variable más sensible a los valores extremos.

5. Simulación Monte Carlo

La simulación utiliza $P(H) = 0{,}3105$, $P(CHD \mid H) = 0{,}2470$ y $P(CHD \mid \neg H) = 0{,}1092$. Para cada cohorte se genera primero la hipertensión y luego CHD condicionado a ese estado. Los parámetros permanecen fijos y las personas se consideran independientes.

Resultado	Valor
Tasa global observada y teórica	15,20 %
Media de las 10.000 cohortes	15,19 %
Desviación entre cohortes	1,13 puntos porcentuales
MCSE de la media simulada	0,0113 puntos porcentuales
Rango predictivo central 95 %	13,0 %–17,4 %
Percentil 99	17,9 %
$P(\text{tasa} \geq 18\,\%)$	0,88 %

Cuadro 4: Resumen de 10.000 cohortes simuladas de 1.000 personas.

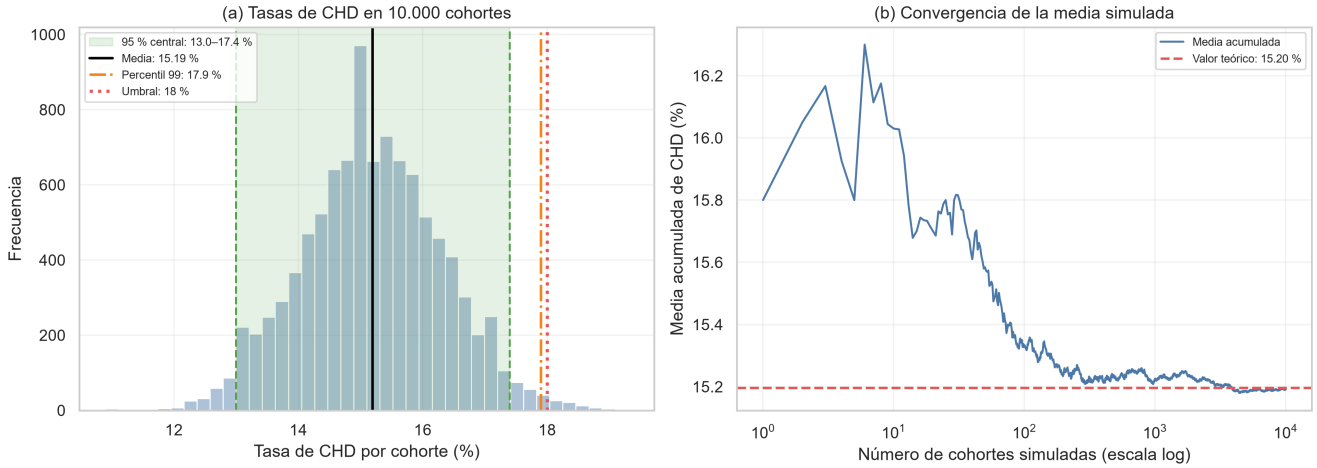


Figura 4. Distribución de tasas simuladas y convergencia de la media.

La media de las cohortes simuladas fue 15,19 %, muy cercana al 15,20 % esperado a partir de los parámetros usados. Esto comprueba que la simulación fue implementada de manera coherente, pero no constituye una validación en otra población porque las probabilidades provienen de los mismos datos. El rango 13,0 %–17,4 % describe variación entre cohortes simuladas, no un intervalo de confianza poblacional. El umbral de 18 % es analítico y no un punto de corte clínico.

6. Análisis de robustez

Variable	Media	Mediana	Recortada 5 %	Winsorizada	EE jack.	Extremo influyente
Edad	49,585	49,0	49,447	49,583	0,1317	70
Presión sistólica	132,352	128,0	130,906	132,240	0,3385	295
Colesterol total	236,722	234,0	235,193	236,407	0,6890	696

Cuadro 5: Sensibilidad de tendencia central e influencia jackknife.

La diferencia de presión sistólica cambió poco al limitar los valores extremos: pasó de 13,29 a 12,78 mmHg. Con medias recortadas fue de 13,15 mmHg y su intervalo bootstrap, de 10,99 a 15,35 mmHg, permaneció por encima de cero. Por tanto, la diferencia no parece depender de unas pocas observaciones extremas. Las correlaciones también conservaron su signo, aunque glucosa mostró el mayor cambio, de 0,1255 a 0,1088, y debe interpretarse con más cautela.

7. Preparación para la Sumativa 3

Resultado	Evidencia de S2	Estado	Recomendación
Medias principales	IC clásico, percentil y BCa coinciden	Robusto	Controlar extremos dentro del entrenamiento.
Diferencia de sysBP	Permutación, winsorización y recorte coinciden	Robusto como asociación	Ajustar confusores; no inferir causalidad.
Correlaciones	$r = 0{,}082$–$0{,}225$; IC excluyen cero	Estable pero débil	No elegir variables solo por correlación marginal.
Glucosa	r: 0,1255 a 0,1088; $n = 3.850$	Usar con cautela	Estudiar faltantes y extremos.
Tasa de CHD	15,20 % observada; 15,19 % simulada	Coherente bajo supuestos	Estratificar y validar fuera de muestra.
Calidad de datos	sysBP=295; colesterol=696; faltantes	Revisar	Verificar plausibilidad e imputar sin fuga.

Cuadro 6: Síntesis para la etapa predictiva.

Antes de imputar, escalar, transformar o winsorizar se deben separar las particiones; cada operación se ajustará solo con entrenamiento. Dado que CHD ocurre en 15,2 %, se recomiendan particiones estratificadas y evaluación de discriminación y calibración fuera de muestra.

8. Conclusiones

Ninguna de las comprobaciones realizadas cambió las conclusiones principales de la Sumativa 1. La edad y la presión sistólica mostraron los resultados más estables dentro de esta muestra, por lo que tiene sentido considerarlas en la siguiente etapa. Las correlaciones conservaron el signo, pero fueron pequeñas y no demuestran capacidad predictiva por sí solas. Glucosa requiere más cautela por sus datos faltantes y su mayor sensibilidad a los extremos. Estas conclusiones orientan la modelación, pero todavía deben comprobarse fuera de muestra y no permiten establecer causalidad.

Referencias

[1] Dileep. (2019). *Logistic regression to predict heart disease* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression

[2] Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association, 82*(397), 171–185. https://doi.org/10.1080/01621459.1987.10478410

[3] Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

[4] Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.a ed.). Springer.

[5] National Heart, Lung, and Blood Institute. (s. f.). *Teaching datasets: Framingham Heart Study*. https://biolincc.nhlbi.nih.gov/teaching/

[6] Robert, C. P., & Casella, G. (2004). *Monte Carlo statistical methods* (2.a ed.). Springer.

[7] Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Notebook reproducible ejecutado con semilla 42. Todas las figuras fueron exportadas a 300 dpi y los datos originales permanecieron sin cambios.